

Previsão de consumo de energia elétrica utilizando sistema Neuro-Fuzzy ANFIS

Carlos Gabriel Ribeiro¹, Afonso Consoli²
IMECC, Campinas, SP

Resumo. A previsão do consumo de energia elétrica em ambientes residenciais envolve variáveis complexas e incertezas que desafiam os modelos tradicionais. Este trabalho propõe a aplicação de um sistema ANFIS (Adaptive Neuro-Fuzzy Inference System) para prever a potência ativa média global em função de variáveis como potência reativa, corrente e tensão. O desempenho do ANFIS foi comparado com uma rede neural MLP (Multilayer Perceptron) do pacote Scikit-Learn. Foram analisadas diferentes configurações com variação do número de regras fuzzy, épocas de treinamento e taxas de aprendizado. Os resultados mostram que o ANFIS apresenta desempenho competitivo, especialmente em contextos com poucos dados e alta incerteza, mantendo alta interpretabilidade e robustez.

Palavras-chave. Neuro-Fuzzy, Sistema ANFIS, Redes Neurais, Lógica Fuzzy, Previsão Energética.

1 Introdução

O presente projeto tem como objetivo o desenvolvimento de um modelo de previsão de consumo de energia elétrica utilizando um sistema neuro-fuzzy. Este tipo de sistema combina a lógica fuzzy — eficiente no tratamento de incertezas — com a capacidade de aprendizado de redes neurais, permitindo a geração automática e otimizada de regras para modelar fenômenos complexos. Utilizando dados públicos de consumo residencial de energia, o modelo será treinado para realizar previsões baseadas em variáveis como potência reativa, corrente e tensão. A metodologia envolverá coleta e pré-processamento dos dados, construção do sistema neuro-fuzzy (usando o modelo ANFIS), treinamento supervisionado e avaliação de desempenho. O projeto visa demonstrar a eficiência de abordagens híbridas no campo da inteligência computacional para problemas reais de previsão de séries temporais.

2 Fundamentação Teórica

2.1 Sistemas Baseados em Regras

Um sistema de base de regras fuzzy é uma abordagem computacional que utiliza lógica difusa para representar e manipular conhecimento baseado em regras linguísticas, permitindo lidar com incertezas e informações imprecisas de maneira similar ao raciocínio humano. Nesse tipo de sistema, o comportamento é descrito por um conjunto de regras do tipo “SE...ENTÃO”, que relacionam variáveis de entrada e saída por meio de expressões linguísticas. Essas regras, combinadas com mecanismos de inferência e tratamento das informações, permitem que o sistema tome decisões mesmo quando os dados disponíveis não são exatos ou completos.

O funcionamento de um sistema fuzzy baseado em regras ocorre em quatro etapas principais:

2.1.1 Fuzzificação

Nessa etapa, os valores de entrada (precisos) são convertidos em valores fuzzy, ou seja, expressos em termos de graus de pertencimento a conjuntos linguísticos (como “baixo”, “médio” ou “alto”), por meio de funções de pertinência.

2.1.2 Base de Regras

É o conjunto de regras linguísticas definidas por especialistas, que estabelecem relações entre as variáveis de entrada e saída. Essas regras seguem uma estrutura do tipo "SE condição, ENTÃO ação".

¹c232791@dac.unicamp.br

²a193367@dac.unicamp.br

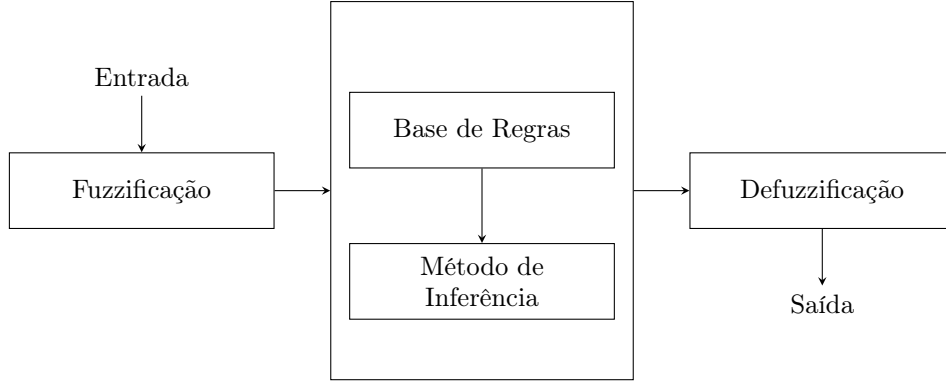


Figura 1: Arquitetura de um sistema de base de regras fuzzy [santos2018]

Tabela 1: Estrutura geral de uma regra fuzzy com múltiplas entradas e saídas [barros2016].

Se	x_1 é A_1	e	x_2 é A_2	é	\dots	x_n é A_n
Então	u_1 é B_1	e	u_2 é B_2	e	\dots	u_m é B_m

2.1.3 Método de Inferência

Avalia quais regras são ativadas de acordo com os valores fuzzy das entradas e combina os resultados das regras aplicáveis para gerar uma saída fuzzy.

2.1.4 Defuzzificação

Converte os resultados fuzzy obtidos na inferência em um valor final preciso (crisp), que pode ser utilizado em decisões ou ações concretas pelo sistema.

Essas etapas, em conjunto, permitem que o sistema simule o raciocínio aproximado e interpretativo, característico da tomada de decisões humanas.

2.2 Método de Takagi - Sugeno

O método de Takagi-Sugeno (TS) é um paradigma fundamental na teoria dos sistemas fuzzy, caracterizado por sua estrutura híbrida que combina lógica nebulosa com funções matemáticas analíticas. Sua principal diferença em relação aos modelos linguísticos tradicionais, como o de Mamdani, reside na formulação do consequente das regras: enquanto sistemas clássicos usam conjuntos fuzzy para descrever saídas, o modelo TS emprega funções explícitas das variáveis de entrada, tipicamente lineares (embora possam ser não lineares). Essa escolha confere ao método maior eficiência computacional e precisão na modelagem de sistemas dinâmicos complexos.

O processo de inferência no modelo Takagi-Sugeno inicia-se com a avaliação do antecedente fuzzy, onde as variáveis de entrada são mapeadas em conjuntos nebulosos (por exemplo, "Baixo", "Médio", "Alto") por meio de funções de pertinência (μ). Cada regra R_i possui a forma:

$$R_i : \text{SE } x_1 \text{ é } A_{i1} \text{ E } x_2 \text{ é } A_{i2} \text{ ENTÃO } y_i = f_i(x_1, x_2, \dots, x_n) \quad (1)$$

em que A_{ij} são conjuntos fuzzy e f_i é uma função do consequente (geralmente um polinômio). O grau de ativação w_i de cada regra é calculado como o produto (ou mínimo) das pertinências dos antecedentes. Para um sistema com duas entradas x_1 e x_2 :

$$w_i = \mu_{A_{i1}}(x_1) \times \mu_{A_{i2}}(x_2) \quad (2)$$

No passo seguinte, as saídas parciais y_i são computadas aplicando-se as funções do consequente. Por exemplo, para um modelo TS de primeira ordem:

$$y_i = a_{i0} + a_{i1}x_1 + a_{i2}x_2 + \dots + a_{in}x_n \quad (3)$$

A saída final do sistema é obtida pela média ponderada das saídas parciais, normalizada pelos graus de ativação:

$$y = \frac{\sum_{i=1}^N w_i \cdot y_i}{\sum_{i=1}^N w_i} \quad (4)$$

onde N é o número de regras. Essa fórmula elimina a necessidade de defuzzificação complexa, simplificando o cálculo.

A eficácia do método Takagi-Sugeno deriva justamente desta combinação: a divisão fuzzy do espaço de entrada (que captura não linearidades) e as funções locais do consequente (que permitem análise matemática rigorosa). Suas aplicações estendem-se desde controle de robôs até modelagem econômica, sempre que se requer equilíbrio entre interpretabilidade e precisão numérica.

Para contextos onde a interpretação linguística é essencial, modelos TS podem ser estendidos com termos nebulosos no consequente, mas sua força permanece na integração elegante entre lógica e álgebra.

2.3 Sistemas Neuro - Fuzzy

Um Sistema Neuro-Fuzzy é um tipo de sistema híbrido, constituído pela combinação de duas técnicas de modelagem amplamente conhecidas — as Redes Neurais Artificiais (RNA) e os Sistemas Fuzzy (SF) — com o objetivo de criar soluções mais robustas e menos suscetíveis às limitações individuais de cada abordagem. A ideia central de um SNF é a construção de um Sistema de Inferência Fuzzy (FIS) em uma estrutura paralela e distribuída, de forma que os algoritmos de aprendizado das redes neurais possam ser aproveitados para ajustar automaticamente os parâmetros do FIS.

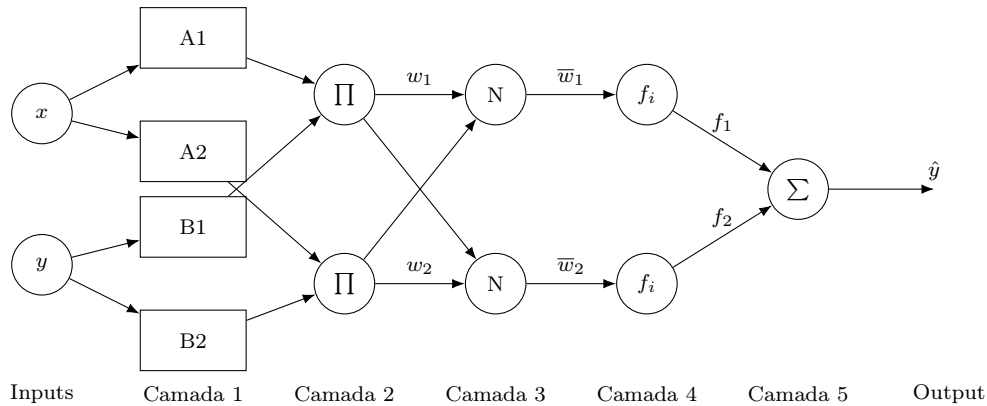


Figura 2: Arquitetura ANFIS com 2 entradas e 2 regras.

2.3.1 Vantagens e Desvantagens

Como toda abordagem metodológica, a modelagem de problemas apresenta vantagens e limitações inerentes. A seguir, destacam-se alguns dos principais aspectos positivos e negativos envolvidos nesse processo.

Os sistemas Neuro-Fuzzy (SNF) representam uma abordagem híbrida que combina as vantagens complementares da lógica fuzzy e das redes neurais artificiais (RNA), oferecendo soluções robustas para problemas complexos. Entre as principais vantagens, destaca-se a integração harmoniosa entre o conhecimento qualitativo da lógica fuzzy — que proporciona uma interface intuitiva e de fácil interpretação — e a capacidade de aprendizado automático das RNA, eficaz na extração de padrões e modelagem de sistemas mesmo sem conhecimento prévio detalhado. Além disso, os SNF são altamente adaptáveis, podendo ser aplicados a diversos contextos, e demonstram robustez no tratamento de dados ruidosos, superando muitas limitações das redes neurais convencionais. Outro ponto forte é sua capacidade de autoaprendizado e autodirecionamento, que imita processos humanos de tomada de decisão, incluindo auto-organização e ajuste contínuo.

Por outro lado, os SNF também apresentam desvantagens significativas. Uma das principais limitações é a restrição quanto ao número de variáveis de entrada, devido ao problema da explosão combinatória de regras: à medida que as entradas aumentam, o custo computacional cresce exponencialmente, reduzindo a eficiência do sistema. Além disso, os SNF frequentemente possuem estruturas rígidas, o que dificulta adaptações ou expansões posteriores. Mesmo quando há flexibilidade para modificações, a escalabilidade do modelo é comprometida pelo manejo de um número excessivo de regras, tornando-o menos viável para problemas de grande dimensão.

2.3.2 Modelo ANFIS

Um exemplo de SNF é o ANFIS (Adaptive Neuro-Fuzzy Inference System), ou sistema de inferência fuzzy baseado em rede adaptativa. Desenvolvido no início da década de 1990 [jang1993], o ANFIS é uma arquitetura que combina redes neurais artificiais com sistemas de inferência fuzzy do tipo Takagi-Sugeno. Ao integrar a capacidade de aprendizado das redes neurais com o raciocínio aproximado e interpretável da lógica fuzzy, o ANFIS consegue reunir os pontos fortes de ambas as abordagens em uma única estrutura coesa e adaptativa.

3 Metodologia

3.1 Descrição do Problema

O consumo de energia elétrica em ambientes residenciais apresenta um comportamento intrinsecamente não linear e altamente dinâmico, influenciado por diversos fatores internos (como hábitos de uso de aparelhos) e externos (variações de tensão na rede, condições ambientais, etc.). Esse caráter estocástico e a presença de incertezas tornam a modelagem preditiva deste fenômeno um desafio significativo para abordagens estatísticas convencionais, que assumem linearidade ou distribuições bem comportadas.

Neste trabalho, o problema considerado é a previsão da potência ativa média global (*Global Active Power*) consumida por uma residência, com base em um conjunto de variáveis de entrada medidas em tempo real. As variáveis utilizadas como entrada do modelo são: a potência reativa média global (*Global Reactive Power*), a intensidade média da corrente elétrica (*Global Intensity*) e a tensão média por minuto (*Voltage*). Estas variáveis estão disponíveis na base de dados pública *Individual Household Electric Power Consumption*, fornecida pelo *UCI Machine Learning Repository* [torgo2007].

Visando superar as limitações das abordagens puramente estatísticas ou puramente neurais, propõe-se a utilização de um sistema neuro-fuzzy do tipo ANFIS. Esta arquitetura combina a capacidade de aprendizado automático das redes neurais com a interpretabilidade e flexibilidade da lógica fuzzy, permitindo modelar relações complexas entre variáveis com um nível elevado de transparência na inferência. A proposta será comparada a um modelo baseado em rede neural MLP (*Multilayer Perceptron*) em diferentes configurações de treinamento, com o intuito de avaliar a relação entre acurácia e interpretabilidade em cenários realistas de previsão energética.

3.2 Modelagem

A estrutura do modelo proposto baseia-se na arquitetura clássica do ANFIS (Adaptive Neuro-Fuzzy Inference System), conforme descrito por Jang em [jang1993]. O ANFIS é um sistema de inferência fuzzy do tipo Takagi-Sugeno de primeira ordem, implementado com cinco camadas funcionais organizadas sequencialmente. A modelagem matemática de cada camada está detalhada a seguir:

1. **Camada 1 — Fuzzificação:** Nesta camada, cada variável de entrada x_j é associada a um conjunto de funções de pertinência gaussianas do tipo:

$$\mu_{A_j^i}(x_j) = \exp\left(-\frac{(x_j - c_j^i)^2}{2\sigma_j^{i2}}\right) \quad (5)$$

onde c_j^i e σ_j^i são, respectivamente, o centro e o desvio padrão da função de pertinência associada ao i -ésimo conjunto fuzzy da variável x_j . Esses parâmetros são ajustáveis durante o treinamento.

2. **Camada 2 — Cálculo da Ativação das Regras:** Cada regra fuzzy é ativada por meio do produto das funções de pertinência associadas às variáveis de entrada:

$$w_i = \prod_{j=1}^n \mu_{A_j^i}(x_j) \quad (6)$$

sendo w_i o grau de ativação da i -ésima regra.

3. **Camada 3 — Normalização:** Os graus de ativação são normalizados de forma que:

$$\bar{w}_i = \frac{w_i}{\sum_{k=1}^N w_k} \quad (7)$$

garantindo que a soma das ativações normalizadas seja igual a 1.

4. **Camada 4 — Inferência:** Cada regra possui um consequente linear da forma:

$$z_i = p_i x_1 + q_i x_2 + r_i x_3 + s_i \quad (8)$$

onde os coeficientes p_i , q_i , r_i e s_i são parâmetros treináveis. A saída ponderada da regra é:

$$f_i = \bar{w}_i \cdot z_i \quad (9)$$

5. **Camada 5 — Agregação:** A saída final do sistema é obtida por meio da soma das saídas ponderadas de todas as regras:

$$\hat{y} = \sum_{i=1}^N f_i = \sum_{i=1}^N \bar{w}_i \cdot z_i \quad (10)$$

O treinamento do ANFIS foi realizado por meio da descida do gradiente, com o objetivo de minimizar a função de perda baseada no erro quadrático médio (MSE). Tanto os parâmetros das funções de pertinência (camada 1) quanto os coeficientes lineares dos consequentes (camada 4) foram ajustados iterativamente. Foram testadas diferentes taxas de aprendizado e números de épocas, visando obter um modelo estável e com baixo erro.

Para fins comparativos, foi implementado um modelo de rede neural MLP com duas camadas ocultas contendo 10 neurônios cada, função de ativação ReLU, otimizador Adam e função de perda MSE. A biblioteca `Scikit-learn` foi utilizada para esta implementação. Os dados foram normalizados e os dois modelos (ANFIS e MLP) foram avaliados sob as mesmas condições de entrada, utilizando a mesma divisão treino/teste e os mesmos critérios de avaliação. O código-fonte completo dos experimentos está disponível publicamente em [ribeiro2025].

4 Resultados

A avaliação comparativa dos modelos ANFIS e MLP foi conduzida com o objetivo de verificar a eficácia de cada abordagem na tarefa de previsão da potência ativa média global (*Global Active Power*) em ambiente residencial. Ambos os modelos foram treinados utilizando o mesmo subconjunto de dados extraído da base disponibilizada pelo UCI Machine Learning Repository, com particionamento de 80% para treino e 20% para teste. Todos os dados foram previamente normalizados para o intervalo $[0, 1]$ com base nas estatísticas do conjunto de treinamento, a fim de evitar viés e garantir a estabilidade do processo de aprendizado.

4.1 Métricas de Avaliação

A avaliação do desempenho dos modelos foi baseada em três métricas amplamente utilizadas na literatura de regressão:

- **MAE (Erro Absoluto Médio):**

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (11)$$

que fornece a média dos desvios absolutos entre os valores reais y_i e os valores previstos \hat{y}_i .

- **RMSE (Raiz do Erro Quadrático Médio):**

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (12)$$

que penaliza mais fortemente grandes erros, sendo sensível a outliers.

- **Coefficiente de Determinação R^2 :**

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (13)$$

que representa a proporção da variância dos dados explicada pelo modelo. Valores próximos de 1 indicam ótimo ajuste.

4.2 Resultados Numéricos

Foram testadas duas configurações distintas do ANFIS, variando o número de regras fuzzy (N), a taxa de aprendizado (LR) e o número de épocas de treinamento. A MLP, implementada com arquitetura fixa, foi avaliada sob os mesmos dados e métricas. Os resultados quantitativos são apresentados na Tabela 2.

Tabela 2: Comparação de desempenho entre ANFIS e MLP em diferentes configurações

Modelo	MAE	RMSE	R^2
ANFIS (2 regras, 50 épocas, LR = 0,05)	0,0265	0,0362	0,9989
MLP (mesma divisão)	0,0696	0,0824	0,9945
ANFIS (6 regras, 200 épocas, LR = 0,005)	0,0284	0,0407	0,9987
MLP (ajustada)	0,0241	0,0332	0,9991

4.3 Exemplo: ANFIS com 2 Regras

Como destaque, o modelo ANFIS com apenas duas regras apresentou desempenho excelente, superando a MLP em todas as métricas avaliadas. Esse resultado ilustra a capacidade do sistema neuro-fuzzy de capturar relações complexas mesmo com uma estrutura simples. A seguir, apresentamos um exemplo simplificado com duas regras após o treinamento, com base na comparação quantitativa dos modelos mostrada na Tabela 2.




Figura 3: ANFIS (2 regras): valores previstos vs reais




Figura 4: MLP: valores previstos vs reais

4.4 Análise e Discussão

Os resultados indicam que o ANFIS apresenta desempenho competitivo em ambas as configurações, com destaque para o cenário de 2 regras e 50 épocas, no qual superou a MLP em todas as métricas. Isso sugere que, em situações com menor complexidade ou amostras reduzidas, o ANFIS tende a capturar padrões relevantes com maior eficiência, beneficiando-se de sua capacidade de representar conhecimento linguístico com regras simples.

Na configuração com 6 regras e 200 épocas, observou-se uma leve degradação no desempenho do ANFIS, possivelmente devido à sobreparametrização das regras ou ao desafio adicional de ajuste fino dos

parâmetros fuzzy. Nessa situação, a MLP ajustada apresentou melhor desempenho numérico, embora mantenha seu caráter de "caixa-preta", dificultando a interpretação dos resultados.

Em termos de interpretabilidade, o ANFIS permite extrair explicitamente as regras inferenciais que regem o comportamento do sistema, o que pode ser de grande relevância para aplicações críticas em energia, onde decisões baseadas em modelos devem ser justificáveis. Já a MLP, apesar da ligeira superioridade numérica em alguns casos, não oferece esse nível de transparência.

Conclui-se que a escolha entre os modelos deve considerar, além da acurácia, aspectos como interpretabilidade, escalabilidade e o domínio de aplicação. O ANFIS mostra-se particularmente vantajoso em contextos que exigem explicações claras e inteligibilidade do modelo preditivo.

5 Considerações Finais

Este trabalho apresentou o desenvolvimento, implementação e avaliação de um sistema neuro-fuzzy do tipo ANFIS aplicado à previsão da potência ativa média global em ambientes residenciais. A motivação partiu da constatação de que o consumo energético residencial apresenta forte variabilidade, não linearidade e incerteza, o que demanda técnicas mais robustas que os modelos estatísticos convencionais.

A arquitetura computacional do ANFIS foi desenvolvida integralmente, com base no modelo de inferência do tipo Takagi-Sugeno de primeira ordem. O modelo foi treinado utilizando o algoritmo de descida do gradiente, com ajuste conjunto dos parâmetros das funções de pertinência e dos consequentes lineares. Os resultados obtidos foram comparados com os de uma rede neural MLP construída com a biblioteca **Scikit-learn**, utilizando a mesma base de dados e métricas de avaliação.

Os experimentos mostraram que o ANFIS alcança desempenho preditivo equivalente ou superior ao da MLP em cenários de baixa complexidade, mantendo simultaneamente um alto grau de interpretabilidade. Em contextos mais complexos, a MLP superou levemente o ANFIS em termos numéricos, mas sem oferecer mecanismos de explicação compreensíveis para usuários finais ou especialistas.

Como trabalhos futuros, propõe-se:

- Empregar métodos avançados de otimização, como algoritmos genéticos, PSO ou aprendizado híbrido, para calibrar automaticamente as funções de pertinência e regras fuzzy;
- Explorar funções de pertinência alternativas (triangulares, trapezoidais, sigmóides) e modelos hierárquicos que reduzam o número de regras sem comprometer a acurácia;
- Realizar testes com diferentes bases de dados e variáveis contextuais (clima, sazonalidade, perfis de uso) para avaliar a generalização do modelo;

Em síntese, o estudo corrobora o potencial dos sistemas neuro-fuzzy como ferramentas eficazes e interpretáveis para tarefas de previsão em domínios caracterizados por incerteza e não linearidade, como é o caso do consumo de energia elétrica residencial. O equilíbrio entre desempenho preditivo e inteligibilidade torna o ANFIS uma alternativa promissora para aplicações industriais, energéticas e ambientais.

Referências

- [1] Jang, J.-S. R. (1993). ‘ANFIS: sistema de inferência fuzzy baseado em rede adaptativa’. *IEEE Transactions on Systems, Man, and Cybernetics*, **23**(3), 665–685.
- [2] Daniel D. C. Santos. *Um estudo sobre identificação de anomalias em bases de regras fuzzy aplicado à estimação do risco de endometriose*. Master’s thesis, University of Campinas, Campinas, Brazil, 2018.
- [3] Laécio Carvalho Barros, Rodney Carlos Bassanezi, and Weldon Alexander Lodwick. *First Course in Fuzzy Logic, Fuzzy Dynamical Systems, and Biomathematics*. Springer, 2016.
- [4] https://www.maxwell.vrac.puc-rio.br/32823/32823_5.PDF acesso em 05 de Junho de 2025
- [5] C. Ribeiro. *MS580_Neuro-Fuzzy: Implementação dos modelos ANFIS e MLP para previsão de potência ativa*. GitHub, 2025. Disponível em: https://github.com/DarkQuantum-bit/MS580_Neuro-Fuzzy.
- [6] Torgo, L. (2007). ‘Individual household electric power consumption Data Set’. *UCI Machine Learning Repository*. Disponível em: <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>. Acesso em: 05 de maio de 2025.